


# Modelo Espaciotemporal del Rendimiento Académico en Colombia mediante Grafos Dinámicos y Series Temporales (Saber 11, 2015–2026)

Propuesta presentada por:

**John Jairo Prado Piñeres**

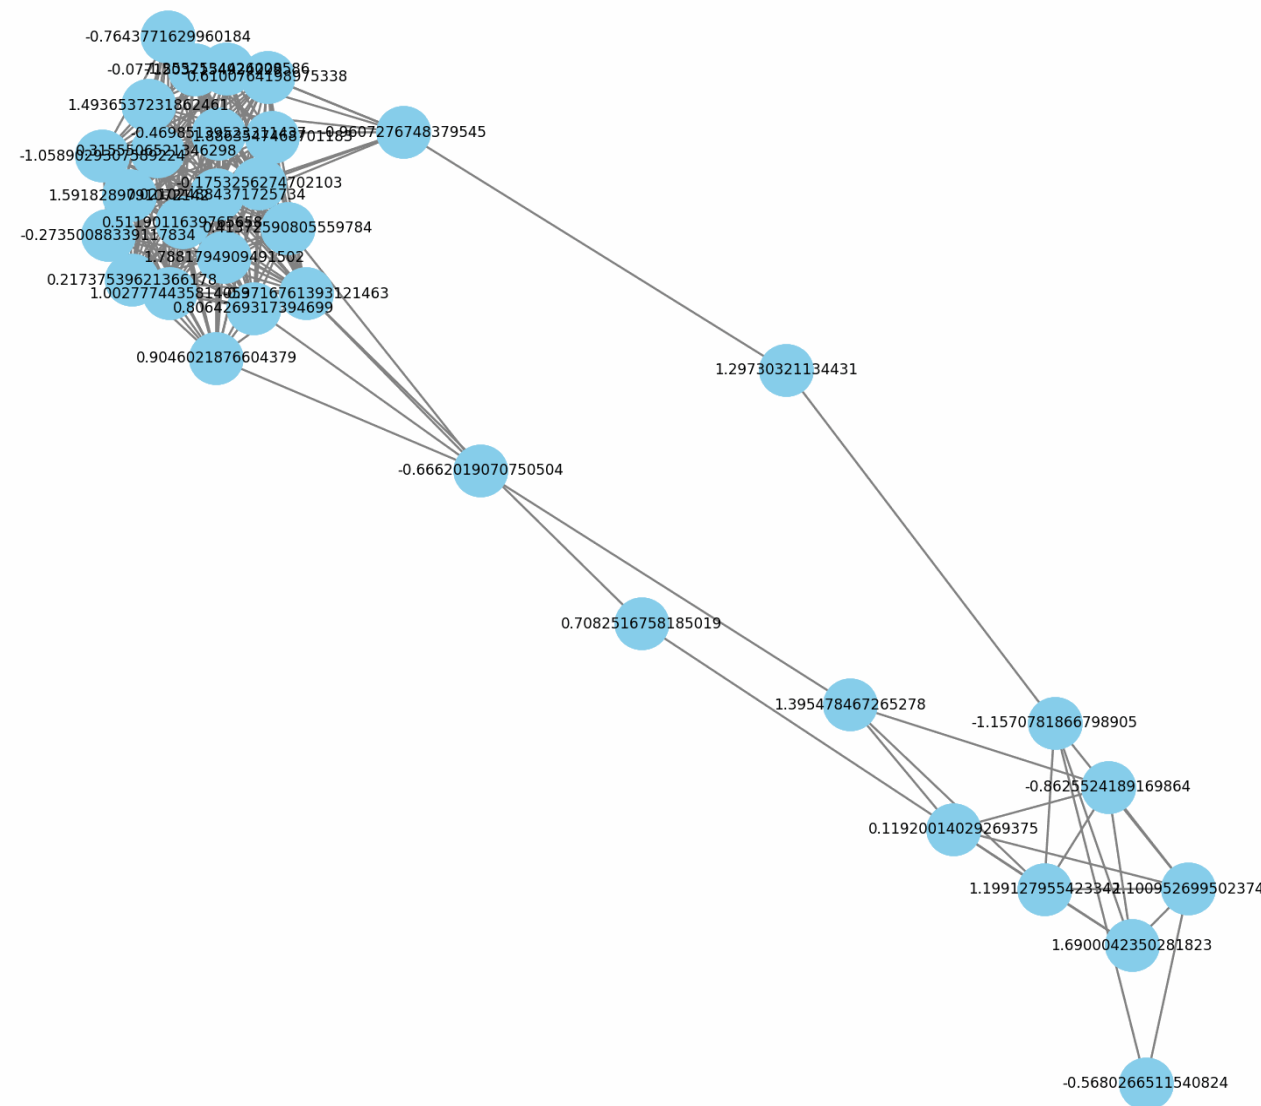
**Gloria Patricia Redondo Alvarado**



**Colombia, 2025**

Proyecto desarrollado para el concurso Datos del Ecosistema (2025),  
Ministerio TIC— Colombia

Grafo Saber 11 - 2015



URL: [datos.gov.co/stories/s/Concurso-Datos-al-Ecosistema-2025/jy2q-75un](https://datos.gov.co/stories/s/Concurso-Datos-al-Ecosistema-2025/jy2q-75un)

Github: <https://github.com/johnky100/modelo-espaciotemporal-saber11>

# Presentación



# Motivación

# MOTIVACIÓN DEL ESTUDIO

## Problema:

El sistema educativo colombiano presenta desigualdades territoriales, rupturas históricas y variabilidad interanual que no han sido analizadas de forma espacio-temporal.

## Necesidad:

Modelos tradicionales no capturan:

- Dependencias espaciales
- Estructuras latentes
- Cambios abruptos (2018, pandemia 2020–2021)

ANIO	PUNT_GLOBAL_PROM
2015	243,01
2016	250,97
2017	248,75
2018	256,16
2019	241,80
2020	269,51
2021	271,85
2022	242,41

# Objetivos

# OBJETIVO

## General:

Desarrollar un modelo espaciotemporal basado en grafos y aprendizaje profundo para caracterizar y predecir la evolución del rendimiento académico (2015–2026).

## Específicos:

Construir grafos educativos anuales mediante similitud del coseno entre departamentos.

Generar embeddings estructurales con GraphSAGE y analizar su evolución espacio–temporal.

Entrenar y comparar modelos predictivos LSTM, ST-GNN y T-GCN para estimar puntajes 2023–2026.



# Recolección de la Información

# DATOS ABIERTOS Datos abiertos utilizados

Datos del ICFES Saber 11 (2015–2022)

Rows: 7.109.704, Columns: 51

Datos departamentales disponibles públicamente

Mapas oficiales GeoJSON de Colombia

Todos los datos replicables desde repositorios abiertos

PERIODO	REGISTROS	VARIABLES	%
2015	570.464	51	14%
2016	563.370	51	14%
2017	561.287	51	14%
2018	32.348	51	1%
2019	1.109.085	51	28%
2020	15.435	51	0%
2021	35.577	51	1%
2022	1.065.888	51	27%
	3.953.454		



# Metodología

# METODOLOGIA AGIL APLICADA AL PROYECTO ESPACIO TEMPORAL

Metodología Híbrida  
Scrum + CRIST DM

Limpieza e imputación MICE



Construcción de grafos  
(2015-2022)



Embeddings GraphSAGE



Visualización 3D con PCA



Modelos departamentales  
(LSTM, ST=GNM, F-GCN)



Comparación integrada

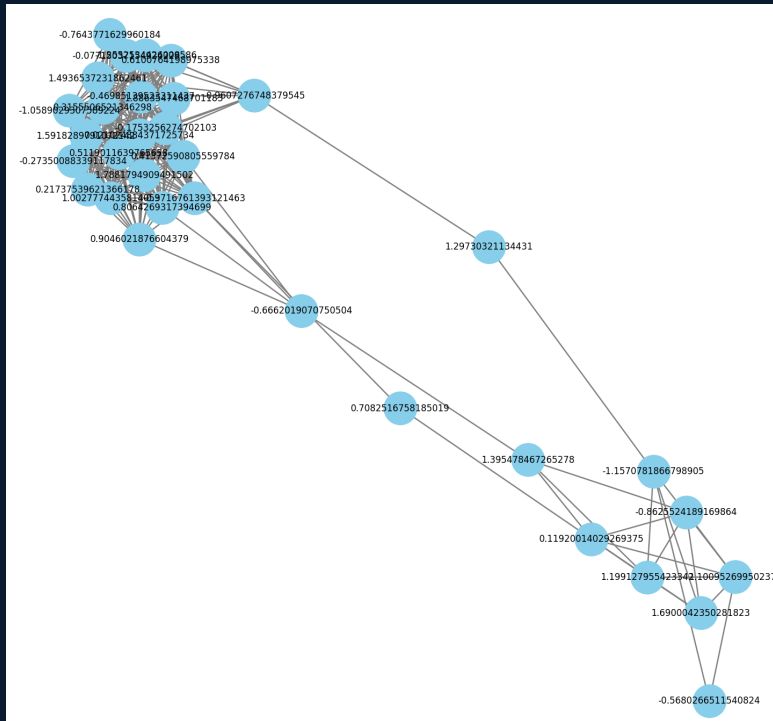
# Resultados

# GRAFOS EDUCATIVOS

## Estructura observada:

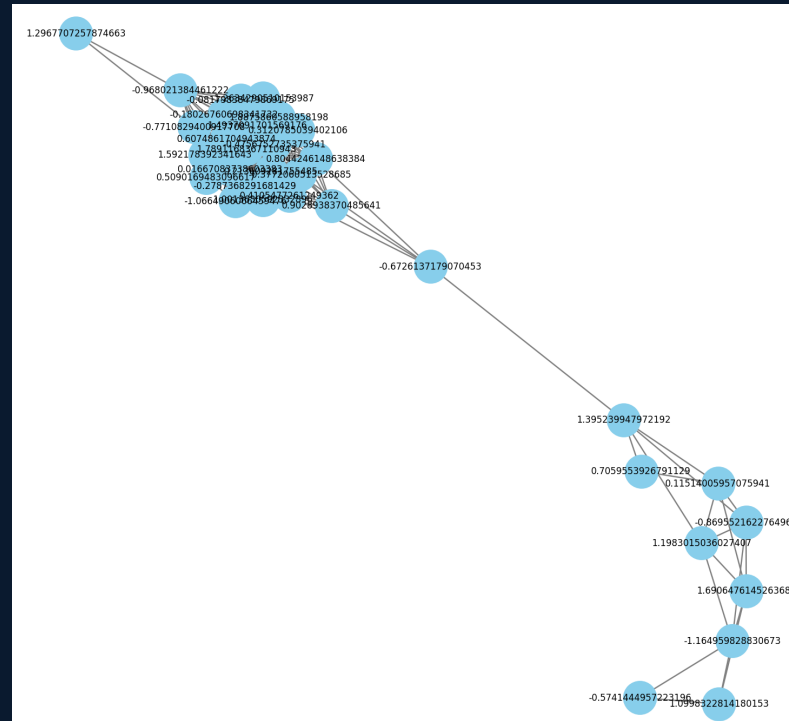
### 2015–2017: Centro–periferia estable.

Año 2015



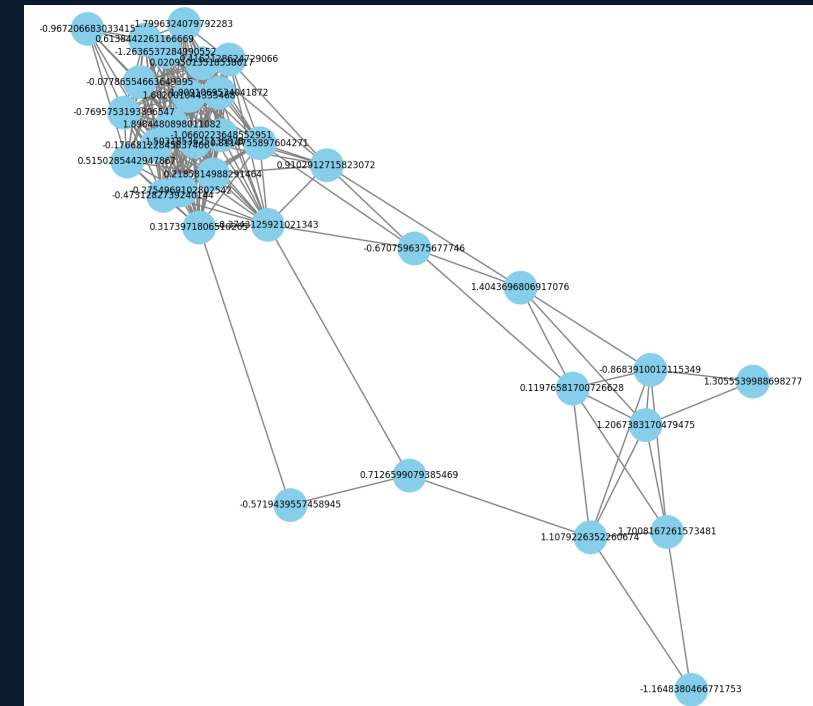
Fuente: Elaboración Propia

Año 2016



Fuente: Elaboración Propia

Año 2017



Fuente: Elaboración Propia



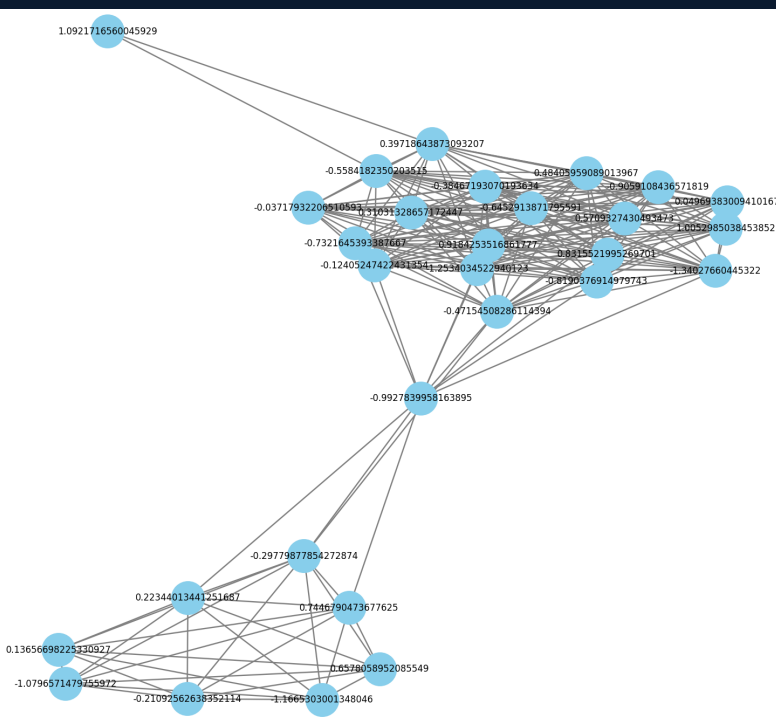
# GRAFOS EDUCATIVOS

## Estructura observada:

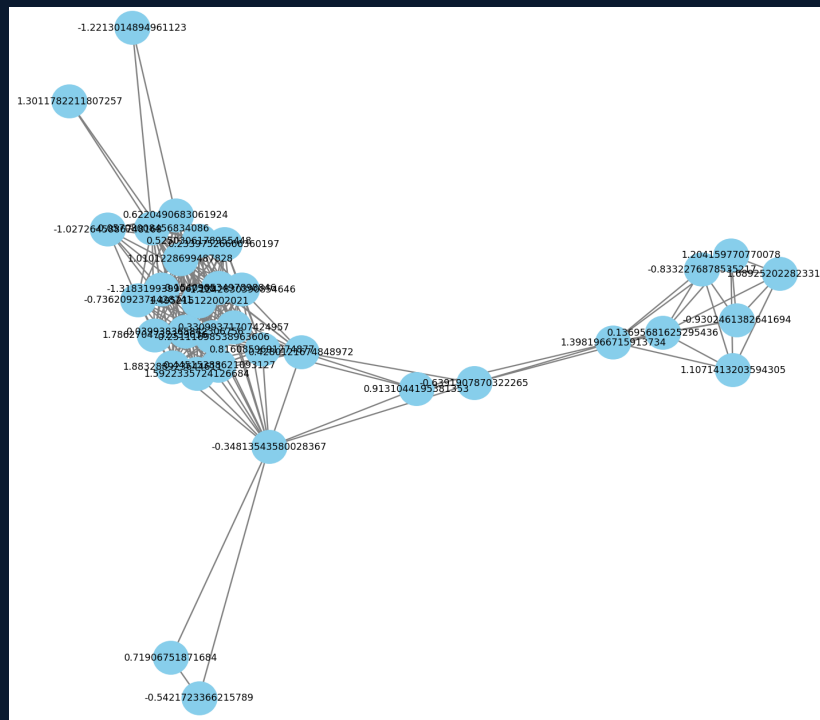
**2018:** Hiperconectado (anomalía). **2019:** Retorno a la normalidad.

**2020:** Fractura por pandemia.

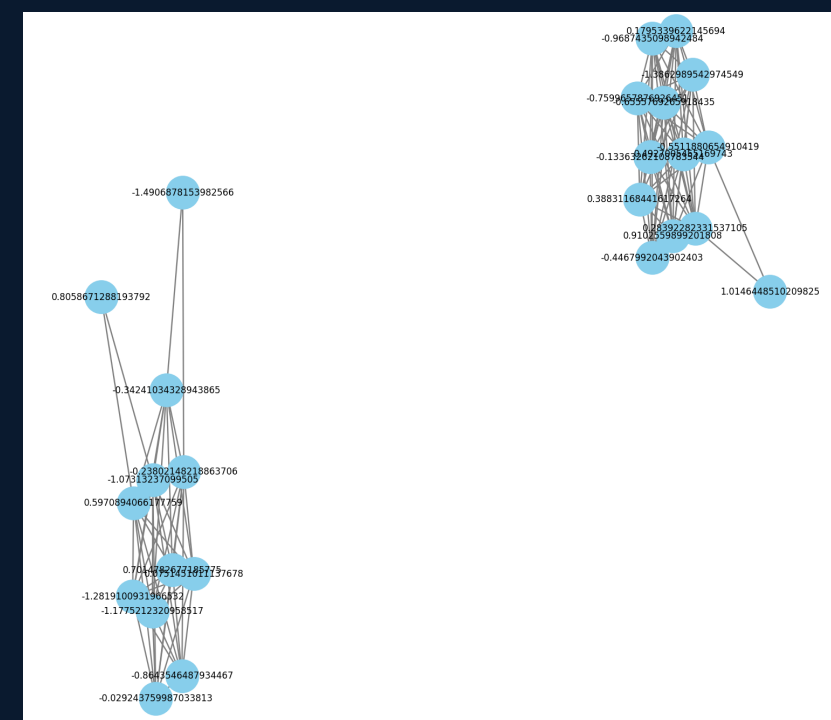
Año 2018



Año 2019



Año 2020



Fuente: Elaboración Propia

Fuente: Elaboración Propia

Fuente: Elaboración Propia

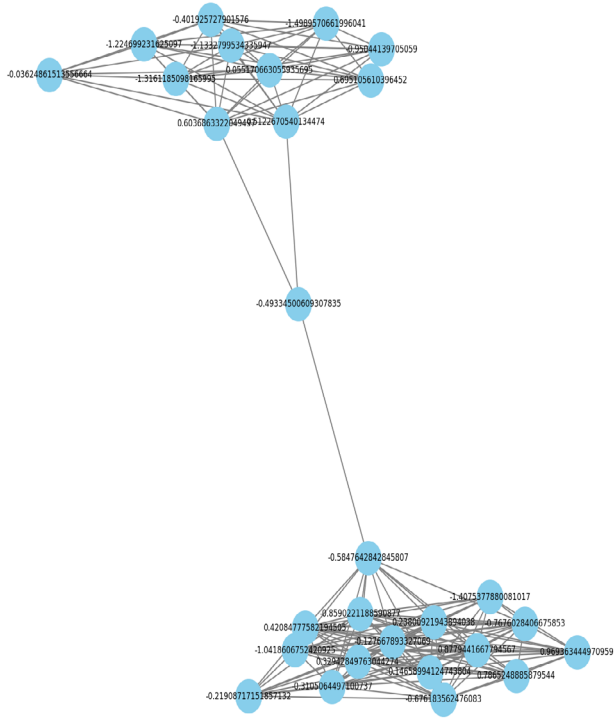
# GRAFOS EDUCATIVOS

## Estructura observada:

2021: Recuperación parcial.

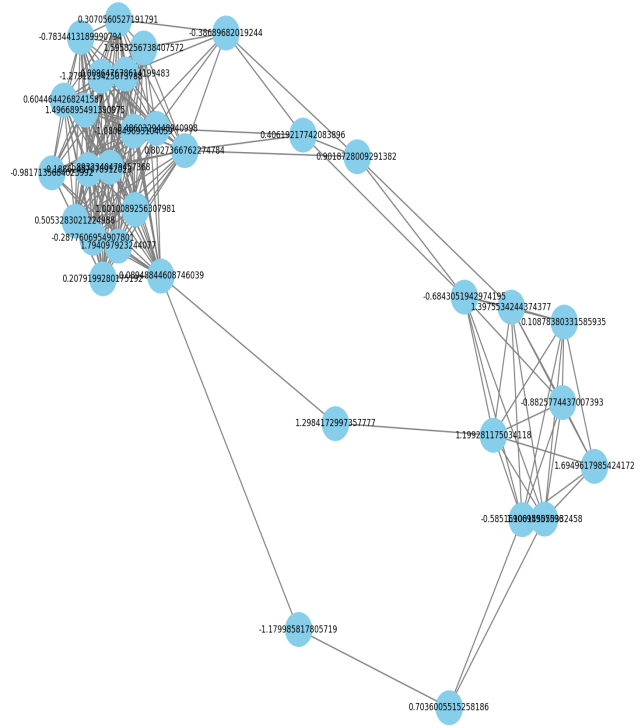
2022: Normalización final.

Año 2021



Fuente: Elaboración Propia

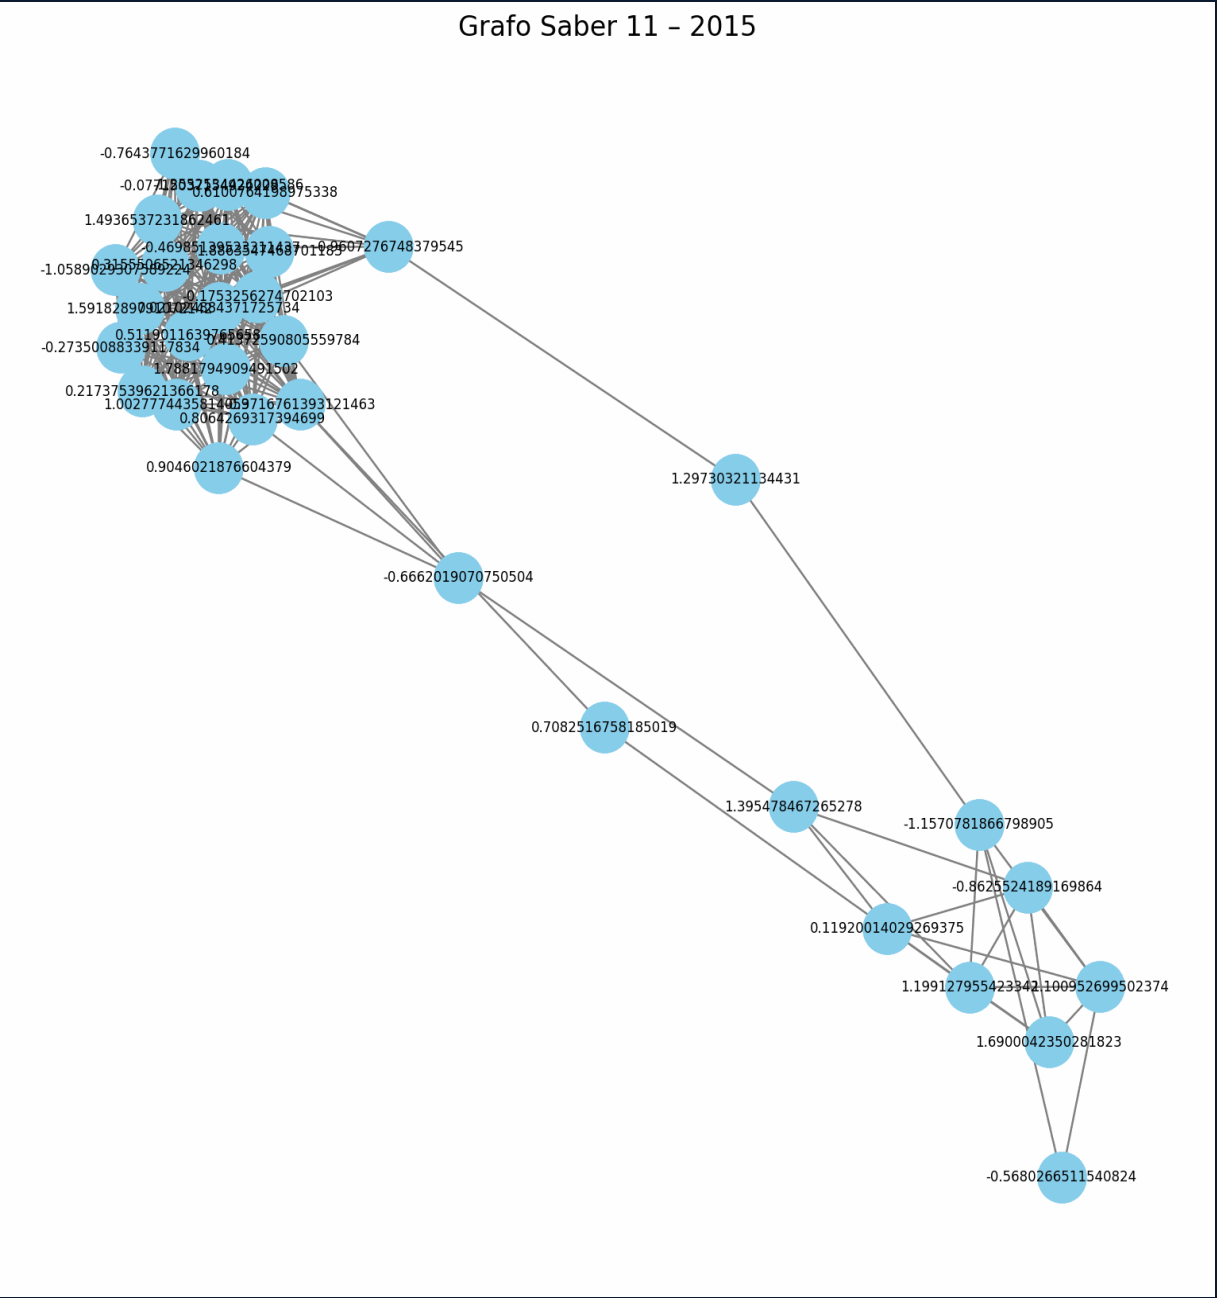
Año 2022



Fuente: Elaboración Propia

Año 2015 - 2022

Grafo Saber 11 - 2015

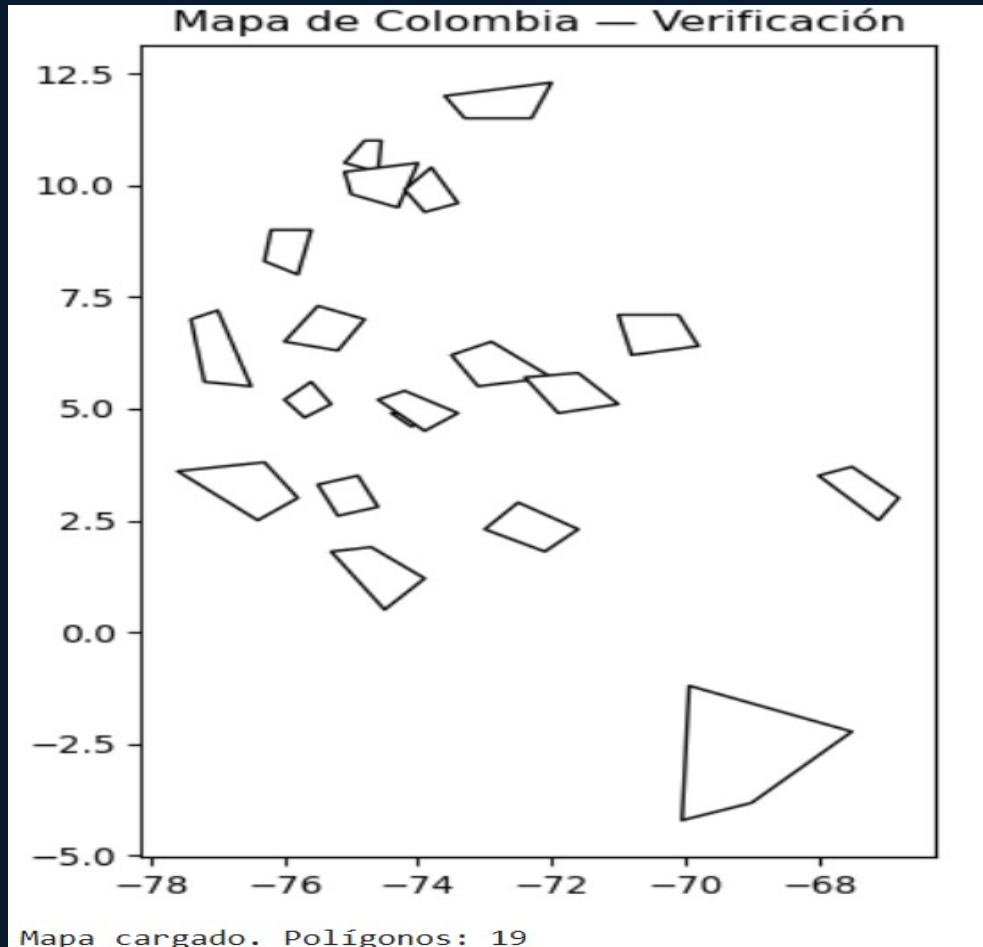


Fuente: Elaboración Propia

# Embeddings GraphSAGE (Graph Sample and Aggregate)

**Hallazgos:** Alta estabilidad en 2016–2017. Rupturas claras en 2018 y 2020. Convergencia en 2021–2022.


PCA 2D



Fuente: Elaboración Propia

PCA 3D

Embedding PCA 3D — Evolución 2015–2022



Fuente: Elaboración Propia

# SERIE REAL 2015–2022

## Patrones observados:

- Estabilidad inicial.
- Ruptura 2018.
- Máximos históricos 2020–2021 (COVID-19).
- Caída severa en 2022.

ANIO	PUNT_GLOBAL_PROM
2015	243,01
2016	250,97
2017	248,75
2018	256,16
2019	241,80
2020	269,51
2021	271,85
2022	242,41



# MODELO PREDICCION SERIES TEMPORALES

## Patrones observados:

### LSTM

Modelo temporal puro.

Predicciones:

2023: 259.51

2024: 261.93

2025: 253.75

2026: 253.75

Interpretación: Sensible a rupturas.

Reproduce oscilaciones reales.

Proyecta variabilidad moderada.

### ST-GNN

Modelo espaciotemporal (GCN + LSTM).

**Predicción única: 247.27**

**Interpretación:**

- Prioriza la estructura espacial.
- Suaviza la variabilidad.
- Representa el “nivel estructural promedio” del país.

# MODELO PREDICCION SERIES TEMPORALES

Patrones observados:

Modelo T-GCN

Modelo híbrido (GCN + GRU).

Predicción: 249.96

Interpretación: Estabilidad moderada.

Equilibrio entre espacio y memoria temporal.

Punto intermedio entre LSTM y ST-GNN.

ANIO	PUNT_PREDICHO	PUNT_PRED_STGNN	PUNT_PRED_TGCN
2023	259,51	247,27	249,96
2024	261,93	247,27	249,96
2025	253,75	247,27	249,96
2026	253,75	247,27	249,96

SERIE REAL  
2015–2022

ANIO	REAL	LSTM	ST-GNN	T-GCN
2015	243,006			
2016	250,9672			
2017	248,7476			
2018	256,1577			
2019	241,8			
2020	269,5141			
2021	271,8485			
2022	242,4079			
2023		259,5072	247,2708	249,9553
2024		261,9348	247,2708	249,9553
2025		253,7486	247,2708	249,9553
2026		253,7486	247,2708	249,9553

# Dashboard



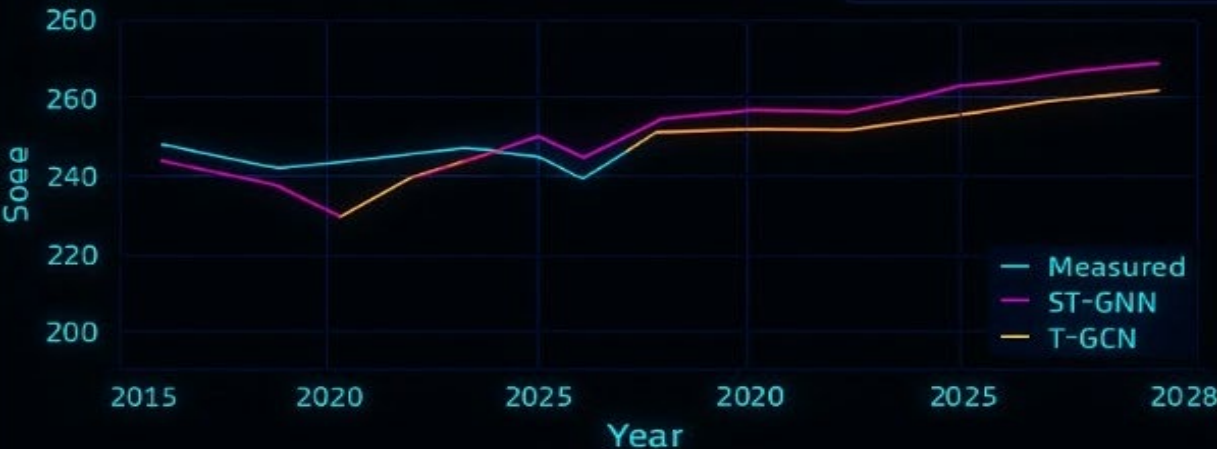
# DASHBOARD CONCEPTUAL

## PROYECTO MODELO ESPACIOTEMPORAL SABER 11


- CONCURSO DATOS AL ECOSISTEMA 2025 -

### TEMPORAL EVOLUTION


Grafos 2015 ▾



### SABER 11



### PCA VISALIZING EMBEDDINGS



### COMPARATIVE PREDICTIONS

LSTM	ST-GNN
2,59	26:19
2613	253,75
25576	255,25
T-GCN	247,27
249,96	

JOHN JAIRO PRADO PIÑERES  
GLORIA PATRICIA REDONDO ALVARADO  
CONCURSO DATOS AL ECOSISTEMA 2025

# Discusión

# DISCUSIÓN

Hallazgos principales:

Las rupturas estructurales están presentes en grafos, embeddings y serie real.

Los modelos GNN tienden a estabilizar las predicciones.

El LSTM reproduce la variabilidad histórica.

Todos convergen a un rango estrecho 247–262 → estabilidad pospandemia.

# Impacto



# IMPACTO Y ESCALABILIDAD

## Impacto Social y Educativo

Identifica brechas territoriales de rendimiento académico con evidencia científica.

Permite focalizar inversión educativa en departamentos vulnerables.

Facilita monitoreo anual de calidad educativa basado en datos abiertos.

Detecta rupturas estructurales para anticipar crisis educativas futuras.

# IMPACTO Y ESCALABILIDAD

## Impacto para la Política Pública

Herramienta para análisis del MEN, ICFES y Secretarías Departamentales.

Sustento técnico para estrategias de mejora educativa diferencial por región.

Aporta a la transparencia y al uso avanzado de datos abiertos en la gestión pública.

# IMPACTO Y ESCALABILIDAD

## Escalabilidad Técnica

Extensible a otros niveles: municipal, institucional y estudiante.

Integrable con nuevas fuentes: SECOP, poblamiento, matrícula, conectividad.

Ampliable a más modelos (EvolveGCN, Graph Transformer, TimeGPT).

Adaptable a dashboards interactivos, sistemas de alerta y analítica en tiempo real.

# IMPACTO Y ESCALABILIDAD

## **Escalabilidad Geográfica y Temporal**

Aplicable a toda la serie histórica (2011–2026).

Reutilizable para pruebas Saber Pro, Saber TyT y educación superior.

## **Valor Estratégico**

Primera propuesta en Colombia con grafos dinámicos + modelos espaciotemporales.

Modelo reproducible y totalmente basado en datos públicos.

# Conclusiones



# CONCLUSIONES

El enfoque espaciotemporal es una herramienta poderosa para analizar educación en Colombia.

Los grafos revelan ciclos de estabilidad, anomalías y recuperación coherentes con la historia reciente.

Los modelos predicen estabilización del desempeño nacional hasta 2026.

LSTM captura variabilidad; ST-GNN y T-GCN estabilidad estructural.

El pipeline constituye un aporte inédito y escalable para investigaciones futuras.

# Aporte

# APORTE INÉDITO

Este es el primer modelo espaciotemporal aplicado al Saber 11 en Colombia que integra grafos, embeddings y modelos GNN para predecir el rendimiento académico nacional.

Metodología original.

Pipeline reproducible.

Extensible a niveles departamentales e institucionales.

Base para futuras políticas públicas basadas en evidencia.

# Referencias

# REFERENCIAS

- Hamilton, W., Ying, R., & Leskovec, J. (2017). Inductive representation learning on large graphs (GraphSAGE). *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- Kipf, T. N., & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. *International Conference on Learning Representations (ICLR)*.
- Zhao, L., Song, Y., Zhang, C., Liu, Y., Wang, P., Lin, T., & Li, H. (2019). T-GCN: A temporal graph convolutional network for traffic prediction. *IEEE Transactions on Intelligent Transportation Systems*, 21(9), 3848–3858.
- Seo, Y., Defferrard, M., Vandergheynst, P., & Bresson, X. (2018). Structured sequence modeling with graph convolutional recurrent networks. *International Conference on Neural Information Processing*.
- Wu, Z., Pan, S., Chen, F., Long, G., Zhang, C., & Yu, P. S. (2020). A comprehensive survey on graph neural networks. *IEEE Transactions on Neural Networks and Learning Systems*, 32(1), 4–24.
- Bronstein, M. M., Bruna, J., LeCun, Y., Szlam, A., & Vandergheynst, P. (2017). Geometric deep learning: Going beyond Euclidean data. *IEEE Signal Processing Magazine*, 34(4), 18–42.
- Li, Y., Yu, R., Shahabi, C., & Liu, Y. (2018). Diffusion convolutional recurrent neural network. *International Conference on Learning Representations (ICLR)*.
- Geng, X., Li, Y., Wang, L., Zhang, L., Yang, Q., & Ye, J. (2019). Spatiotemporal multi-graph convolutional network for ride-hailing demand forecasting. *AAAI Conference on Artificial Intelligence*.
- Guo, K., Zhang, Z., Hu, Y., He, S., Li, J., & Li, Y. (2019). Attention based spatial-temporal graph convolutional networks for traffic flow forecasting. *Proceedings of AAAI*.
- Yu, B., Yin, H., & Zhu, Z. (2018). Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting. *International Joint Conference on Artificial Intelligence (IJCAI)*.
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- Cho, K., Van Merriënboer, B., Bahdanau, D., & Bengio, Y. (2014). On the properties of neural machine translation: Encoder-decoder approaches (GRU). *arXiv preprint arXiv:1409.1259*.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. (Cap. 10–14)
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and machine learning forecasting methods: Concerns and ways forward. *PLoS ONE*, 13(3), e0194889.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts.
- Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065), 20150202.
- Van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9, 2579–2605.
- Buuren, S. van, & Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3), 1–67.
- Azur, M. J., Stuart, E. A., Frangakis, C., & Leaf, P. J. (2011). Multiple imputation by chained equations: What is it and how does it work? *International Journal of Methods in Psychiatric Research*, 20(1), 40–49.



# REFERENCIAS

ICFES. (2019–2024). Resultados nacionales del examen Saber 11. Instituto Colombiano para la Evaluación de la Educación. <https://www.icfes.gov.co>

Ministerio TIC. (2024). Portal de Datos Abiertos del Estado colombiano. <https://www.datos.gov.co>

Departamento Nacional de Planeación – DNP. (2023). Hojas de ruta sectoriales de datos estratégicos. <https://www.dnp.gov.co>

MEN – Ministerio de Educación Nacional. (2023). Estadísticas de la educación media en Colombia.

## 7. Modelamiento educativo, desigualdad y análisis territorial

Bertoni, E., Rojas, N., & Schady, N. (2016). Investigating the effects of school quality on educational outcomes in Latin America. World Bank Policy Research Working Papers.

García, S., Maldonado, D., Perry, G., Rodríguez, C., & Saavedra, J. (2014). Educación en Colombia: Logros y desafíos. Fedesarrollo.

UNESCO. (2022). Global Education Monitoring Report. UNESCO Publishing.

## 8. Evaluación de modelos y machine learning

Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.

Murphy, K. P. (2012). Machine Learning: A Probabilistic Perspective. MIT Press.

OECD. (2020). The impact of COVID-19 on education: Insights from education at a glance 2020.

Zhang, Z., & Cui, P. (2020). Deep learning on graphs. Cambridge University Press.

Kuhn, M., & Johnson, K. (2013). Applied predictive modeling. Springer.

# Cierre

# **CIERRE**

Gracias por su atención.

Quedo atento a sus preguntas.